


Dokumentace analytické pipeline v Pythonu

Samostatná příloha k diplomové práci *Sociální dialog a kolektivní vyjednávání*.

Účel a hranice roury (*pipeline*)


Python část repozitáře vytváří reprodukovatelné obrázky, tabulky a krátké L^AT_EXové vstupy používané v hlavním textu práce. Roura stahuje data z otevřených databází a připravuje výstupy pro řetězec sestavení (*build*) dokumentu práce. Spojuje zdrojová data, lokální mezipaměť (*cache*), jednotlivé analýzy, registr výstupů a L^AT_EXový dokument. Ruční zásahy patří do verzovaných komentářů a obalů (*wrappers*) PGF obrázků, nikoli do generovaných souborů v `latex/texparts/python/`.



Každý analytický skript stahuje data přes projektové pomocné funkce (*helpery*), výstupy zapisuje do cest z `config.py` a před vykreslováním aplikuje jednotný styl. Tím je zajištěno, že změna šablony, barevné palety nebo způsobu exportu nevyžaduje úpravy v jednotlivých souborech nebo hlavním textu.

Řízení generování

Orchestrátor `python/stats_analytics.py` nejprve rekurzivně prochází `latex/main.tex` a vyhledává v něm aktivní `\input` souborů. Zachytává kořeny (*stems*) vložené jako `texparts/python/STEM` nebo `\inputpgffigure{STEM}`. Potom porovná nalezené stemmy s registrem `python/analytics_registry.toml`; spustí pouze ty skupiny, které jsou v textu skutečně použité, a kterým chybí očekávaný výstup, případně ty, které byly vynuceny volbou `-force`. Po dokončení generování navíc provede audit datové kvality – vypíše varování pro záložní (*fallback*) cesty, zkontroluje uvedený rok v popiscích a datech, a upozorní na použití jiného roku než je cílový.



Běžné spuštění

```
cd python
bash run.sh stats_analytics.py          # doplní chybějící aktivní výstupy
bash run.sh stats_analytics.py --list    # vypíše stemmy nalezené v LaTeXu
bash run.sh stats_analytics.py --force all # pregeneruje všechny aktivní skupiny
bash run.sh stats_analytics.py --target-year 2025 # explicitní audit proti cíli 2025
```

Datová kvalita je od května 2026 součástí stejného kroku, nikoli samostatná ruční kontrola. Výchozí cílový rok je 2025; lze jej změnit volbou `-target-year` nebo proměnnou prostředí `DP_TARGET_YEAR`.

Analytické skripty mají používat helpery `warn_fallback(...)` a `warn_non_target_year(...)` z modulu `stattool.data_quality`, takže se do logu promítne každý sekundární zdroj, hardcoded hodnota, expertní odhad i použití jiného roku než 2025.

Výstupem jsou varování v terminálu, L^AT_EX tabulka (vložená níže) a dva soubory pro transparentní deklaraci v popiscích a komentářích:

- `review/data_quality_report.json`: strojově čitelný přehled auditovaných stemmů.
- `review/data_quality_report.md`: stručný report pro lidskou revizi.

Smlouva mezi Pythonem a LaTeXem

Registr je jediným místem, kde se analytický skript mapuje na výstupy. Klíč seskupuje logicky související grafy nebo tabulky; atribut `texparts` určuje stemmy hledané v L^AT_EXu a atribut `pics` slouží pro kontrolu PDF výstupu. PGF výstupy mají navíc v git verzovaný L^AT_EX soubor `latex/texparts/figures/STEM.tex`, v němž lze upravovat řetězce uvnitř grafu a posouvat popisky bez přepisu při dalším běhu Pythonu.

Příklad z registru

```
[income_pps]
script = "analyses/eu_prijem_pps.py"
texparts = ["eu_prijem_pps"]
pics = ["eu_prijem_pps"]
```

Každá analýza má stejnou kostru bez ohledu na zdroj dat: import cest a stylu, stažení dat přes pomocnou funkci, jejich zpracování balíčkem `pandas`, vykreslení PDF nebo PGF a zápis obalu v L^AT_EXu. V PGF podložce (*backend*) se text v grafu vykresluje až v hlavním dokumentu, takže v popiscích fungují L^AT_EXmakra jako jsou jednotky `\SI{}{}` nebo zkratky `\acs{geo-CZ}`.

Kostra analytického skriptu

```
from config import LATEX_TEXPARTS_DIR
from stattool.fetch import fetch_eurostat
from stattool.style import apply_style_pgf, savefig_pgf, save_figure_tex_pgf

COUNTRIES = ["CZ", "AT", "DE", "DK", "PL", "SK"]

apply_style_pgf()
data = fetch_eurostat("dataset_code")
# ... filtrovani, cistení, vypocet ukazatele ...

savefig_pgf(fig, "my_stem")
save_figure_tex_pgf(
    "my_stem",
    caption="Co, uzemni rozsah, rok",
    label="fig:my_stem",
    cite_keys=["eurostat_dataset_code"],
    strings={"title": "Titulek renderovany LaTeXem"},
)
```

Výstupy a ruční úpravy

Podložka PDF vytváří hotový graf a L^AT_EX obal, který PDF vkládá přes `\includegraphics`. Podložka PGF vytváří zdrojový `.pgf` grafický soubor v `python/figures/`, jednořádkový obal v `latex/texparts/python/` a editovatelný soubor s přepisovatelnými řetězci v `latex/texparts/figures/`. Binární doprovodné obrázky PGF exportu se deduplikují do sdílených bitmap v `python/figures/_shared/`. Výsledkem je, že velké mapy mohou zůstat datově generované, ale jejich titulky a textové řetězce lze ladit v L^AT_EXu a velikost na disku je minimální.

- `python/data/`: lokální cache stažených dat, mimo git.
- `python/figures/`: generované PDF/PGF výstupy, mimo git.

- `latex/texparts/python/`: generované vstupy, mimo git.
- `latex/texparts/figures/`: ručně doladitelné PGF wrappery, v gitu.
- `latex/texparts/commentary/`: metodologická a interpretační próza.

Sestavení (*build*) a kontrola

Ve VS Code je běžný postup zprostředkovan recepty LaTeX Workshopu: recepty s analýzami nejprve vytvoří python prostředí `setup_venv`, poté spustí orchestrátor `stats_analytics.py` a poté sestavení dokumentu v L^AT_EXu. Při ručním sestavení lze rouru spustit explicitně nebo nastavit `RUN_PYTHON_ANALYTICS=1` jako háček před sestavením (*pre-build hook*) přes `latexmk`.

Ruční build

```
cd latex
RUN_PYTHON_ANALYTICS=1 latexmk -pdf -interaction=nonstopmode -file-line-error -outdir=build main.tex
pdflatex -synctex=1 -interaction=nonstopmode -file-line-error -output-directory=build
python_pipeline_attachment.tex
```

Je-li recept spuštěn z VS Code, zápis (*log*) z orchestrace se současně ukládá do `latex/build/stats-analytics.log` (případně `stats-analytics-force.log`). Jsou v něm zachyceny všechny varování a chyby, včetně záložních datových cest a upozornění na použitý rok. Stejná upozornění jsou za běhu vytištěna v terminálu nebo uložena ve zprávách v adresáři `review/`.

Chybějící `.pgf` nebo `texparts/python` výstup je třeba řešit spuštěním orchestrátoru, chyba v citaci nebo makru se řeší v `texparts/figures`. Ruční úprava řetězců se za běhu orchestrátoru zapíše do příslušného python skriptu z editovatelného obalu PGF.

Tabulka datové kvality

Následující přehled byl vygenerován při běhu `stats_analytics.py` při sestavení práce.

Obr.	Skript	Dataset(y) a filtry	Poznámky (roky, fallback)
4.24	<code>eu_apz_vydaje.py</code>	OECD LMPEXP (via “load_lmp_active()“)	Roky v popisku: 2004, 2023 Nesedi cílový rok 2025
4.23	<code>eu_bohatstvi_top1_wid.py</code>	World Inequality Database (WID) bulk CSV: <code>https://wid.world/bulk_download/</code>	Roky v popisku: 2024 Nesedi cílový rok 2025
4.19	<code>eu_cenova_hladina.py</code>	Eurostat “prc_ppp_ind“; Eurostat <code>prc_ppp_ind (A.PLI_EU27_2020.GDP., start_period=START_YEAR)</code>	Roky v popisku: 2024 Nesedi cílový rok 2025
4.7	<code>eu_danovy_klin.py</code>	Eurostat, <code>earn_nt_taxwedge (start_period=2015); Eurostat earn_nt_taxwedge (start_period=2015)</code>	Roky v popisku: 2025
4.21	<code>eu_gini_prijem.py</code>	Eurostat, “ilc_di12“; Eurostat <code>ilc_di12 (A.TOTAL.GINI_HND., start_period=START_YEAR)</code>	Roky v popisku: 2003, 2025
4.14	<code>eu_ict_gender.py</code>	Eurostat “isoc_sks_itsps“; Eurostat <code>isoc_sks_itsps (start_period=2015)</code>	Roky v popisku: 2025
4.5	<code>eu_mne_mapa.py</code>	Eurostat “egr_emp“; Eurostat <code>egr_emp (start_period=2015)</code>	Roky v popisku: 2024 Nesedi cílový rok 2025
4.17	<code>eu_odvetvove_mzdy.py</code>	Eurostat <code>lc_lci_lev (f„A.EUR. D1_D4_MD5.{sector_filter}.“, start_period=DISPLAY_YEAR); Eurostat prc_ppp_ind (A.PLI_EU27_2020.GDP., start_period=DISPLAY_YEAR)</code>	Roky v popisku: 2025
4.18	<code>eu_odvetvove_mzdy.py</code>	Eurostat <code>lc_lci_lev (f„A.EUR. D1_D4_MD5.{sector_filter}.“, start_period=DISPLAY_YEAR); Eurostat prc_ppp_ind (A.PLI_EU27_2020.GDP., start_period=DISPLAY_YEAR)</code>	Roky v popisku: 2025
4.8	<code>eu_osvc_mapa.py</code>	Eurostat <code>lfsa_egaps (Employed persons by professional status); Eurostat lfsa_egaps (A.THS_PER.T.Y15-74.EMP+SELF., start_period=2015)</code>	Roky v popisku: 2025

Obr.	Skript	Dataset(y) a filtry	Poznámky (roky, fallback)
4.33	eu_pokryti_kv_mapa.py	ICTWSS AdjCov (adjusted coverage) for most EU-27 countries;	Roky v popisku: 2024 Nesedi cilovy rok 2025
4.20	eu_prijem_distribuce.py	Eurostat ilc_di01 (f,A.{quant_filter}.TC.PPS.{geo_filter}“, start_period=START_YEAR)	Roky v popisku: 2025
4.2	eu_produkтивita_prijem_trajektorie.py	Eurostat nama_10_lp_ulc (A.PC.EU27_2020_MPPS_CP.NLPR_HW., start_period=START_YEAR); Eurostat earn_nt_net (A.PPS.NET.P1_NCH_AW100., start_period=START_YEAR); Eurostat lfsa_ewhan2 (A.TOTAL.EMP.TOTAL.Y15-64.T.HR., start_period=START_YEAR)	Roky v popisku: 2008, 2025
4.42	korelace_analyza.py	Eurostat lfsa_ewhan2 (A.TOTAL.EMP.TOTAL.Y15-64.T.HR., start_period=START_YEAR); Eurostat earn_nt_net (A.PPS.NET.P1_NCH_AW100., start_period=START_YEAR); Eurostat earn_gr_gpgr2 (A.PC.B-S_X_O., start_period=START_YEAR); Eurostat ilc_di12 (A.TOTAL.GINI_HND., start_period=START_YEAR); Eurostat nama_10_lp_ulc (A.PC.EU27_2020_MPPS_CP.NLPR_HW., start_period=START_YEAR)	Roky v popisku: 2024 Nesedi cilovy rok 2025
4.40	practical_ternary_social_dialog.py	Neuvedeno (sdilene helpery nebo staticka data)	Roky v popisku: 2025, 2026 Nesedi cilovy rok 2025
4.41	practical_ternary_social_dialog.py	Neuvedeno (sdilene helpery nebo staticka data)	Rok v popisku: neuvedeno Rok v popisku nenalezen
4.9	problemy_cz_model.py	Model podle legislativy ČR (zákon č. 586/1992 Sb. o daních z příjmů, zákon č. 155/1995 Sb. o důchodovém pojištění, nařízení vlády č. 365/2025 Sb.)	Roky v popisku: 2026 Nesedi cilovy rok 2025
4.29	problemy_dojezdeni.py	Eurostat, “lfst_r_lfe2ecomm“; Eurostat lfst_r_lfe2ecomm (start_period=START_YEAR)	Roky v popisku: 2025
4.28	problemy_dojezdeni.py	Eurostat, “lfst_r_lfe2ecomm“; Eurostat lfst_r_lfe2ecomm (start_period=START_YEAR)	Roky v popisku: 2005, 2025
4.11	problemy_cz_model.py	Model podle legislativy ČR (zákon č. 586/1992 Sb. o daních z příjmů, zákon č. 155/1995 Sb. o důchodovém pojištění, nařízení vlády č. 365/2025 Sb.)	Roky v popisku: 2026 Nesedi cilovy rok 2025
4.12	problemy_stratifikace.py	Eurostat earn_gr_gpgr2 (f,A.PC.B-S_X_O.“, start_period=START_YEAR)	Roky v popisku: 2010, 2024 Nesedi cilovy rok 2025
4.13	problemy_gpg.py	Eurostat earn_gr_gpgr2 (start_period=2018); Eurostat earn_ses_hourly (ses_filter); Eurostat prc_ppp_ind (f,A.PLI_EU27_2020.GDP.{GEO_6}“, start_period=2014)	Roky v popisku: 2022 Nesedi cilovy rok 2025 Fallback vetve: PLI missing for exact SES year; latest available country PLI used for conversion AT, CZ, DE, DK, PL, SK
4.30	problemy_jazyky.py	Eurostat Adult Education Survey (AES), ~5-year rounds (2007/2011/2016/2022); Eurostat edat_aes_l21; Eurostat edat_aes_l22; Eurostat edat_aes_l23	Roky v popisku: 2022 Nesedi cilovy rok 2025
4.10	problemy_mzda_duchod.py	MPSV ISPV (Mzdová sféra), ČSSZ (Statistická ročenka důchodového pojištění)	Roky v popisku: 2024, 2025
4.15	problemy_stratifikace.py	Eurostat earn_gr_gpgr2 (f,A.PC.B-S_X_O.“, start_period=START_YEAR)	Roky v popisku: 2025
4.16	problemy_verejny_soukromy.py	MPSV ISPV / TREXIMA (Mzdová sféra MZS, Platová sféra PLS, rok 2025)	Roky v popisku: 2025
4.22	stav_aroep_dual.py	Eurostat ilc_peps01n (A.PC.TOTAL.T.); Eurostat ilc_di01 (A.D1+D2+D3+D4+D5+D6+D7+D8+D9.TC.PPS+EUR.); Eurostat prc_ppp_ind (A.PLI_EU27_2020.GDP.EU27_2020)	Roky v popisku: 2017, 2025 Fallback vetve: EU27 D3 PPS series missing in years [2010, 2011, 2012, 2013, 2014, 2015, 2016, 2017]; EUR converted to PPS via PLI used as fallback
4.1	stav_hdp_vyvoj.py	Eurostat, nama_10_pc (A.PC.EU27_2020_HAB_MPPS_CP.B1GQ., start_period=START_YEAR); Eurostat nama_10_pc (A.PC.EU27_2020_HAB_MPPS_CP.B1GQ., start_period=START_YEAR)	Roky v popisku: 2004, 2025
4.34	stav_hustota_vyvoj.py	OECD AIAS ICTWSS (via OECD Stats API, dataset “TUD“)	Roky v popisku: 2004, 2024 Nesedi cilovy rok 2025
4.35	stav_ipp_mzdy.py	Eurostat lc_lci_r2_a (f,A.I20.B-S.D1_D4_MD5.{GEO_ALL}“, start_period=START_YEAR - 1)	Roky v popisku: 2007, 2025
4.36	stav_ipp_rozsah.py	MPSV IPP (Informační systém o pracovních podmínkách, 2007–2025)	Roky v popisku: 2007, 2025

Obr.	Skript	Dataset(y) a filtry	Poznámky (roky, fallback)
4.39	stav_kolektivni_spory_vyvoj.py	ČMKOS (Zpráva o průběhu kolektivního vyjednávání v ČR, počty sporů před zprostředkovatelem a rozhodcem, 2013–2025)	Roky v popisku: 2013, 2025
4.6	stav_korporatni_dan.py	OECD CTS_CIT (start_period=START_YEAR)	Roky v popisku: 2023 Nesedi cílový rok 2025
4.38	stav_socialni_mir_mapa.py	ETUI, ILOSTAT a expertní odhady (Social-peace benchmark, 2025)	Roky v popisku: 2025 Fallback vetve: Strike-days benchmark missing for some countries; ternary B4 remains covered by expert scores; B4 benchmark combines ETUI/ILOSTAT with national fallback assumptions for lacunae
4.37	stav_stavky.py	ILOSTAT STR_DAYS_ECO_RT_A; Statistics Denmark ABST1; Eurostat lfsa_ewhun2; Eurostat lfsi_emp_a (A.EMP_LFS.T.Y20-64.THS_PER.DK, start_period=START_YEAR); Eurostat lfsa_ewhun2 (A.TOTAL.EMP.TOTAL.Y15-64.T.HR., start_period=START_YEAR)	Roky v popisku: 2000, 2025
4.4	stav_volna_mista_vyvoj.py	Eurostat jvs_a_r21	Roky v popisku: 2010, 2025 Fallback vetve: Vacancy-rate timeline used B-O aggregate instead of preferred B-S_X_O
4.3	stav_zamestnanost.py	Eurostat, “lfsi_emp_a”; Eurostat lfsi_emp_a (A.EMP_LFS.T.Y20-64.PC_POP., start_period=START_YEAR)	Roky v popisku: 2009, 2025
4.32	vyhled_digit_dovednosti.py	Eurostat “isoc_sk_dskl_i21”; Eurostat isoc_sk_dskl_i21 (A.IND_TOTAL.I_DSK2_AB.PC_IND., start_period=2021)	Roky v popisku: 2025
4.27	vyhled_porodnost.py	Eurostat, demo_find (A.TOTFERRT., start_period=START_YEAR); Eurostat demo_find (A.TOTFERRT., start_period=START_YEAR)	Roky v popisku: 2024 Nesedi cílový rok 2025
4.26	vyhled_porodnost.py	Eurostat, demo_find (A.TOTFERRT., start_period=START_YEAR); Eurostat demo_find (A.TOTFERRT., start_period=START_YEAR)	Roky v popisku: 1990, 2024 Nesedi cílový rok 2025
4.31	vyhled_vzdelani.py	Eurostat “edat_lfse_03”; Eurostat edat_lfse_03 (A.T.Y25-64.PC.ED5-8., start_period=START_YEAR)	Roky v popisku: 2004, 2025
4.25	vyhled_zavislost.py	Eurostat, “demo_pjanind”; Eurostat demo_pjanind (A.OLDDEP1., start_period=START_YEAR)	Roky v popisku: 2025